1 Import library

In [1]:

```
from matplotlib import pyplot as plt
import sklearn
import pandas as pd
import time
```

In [2]:

```
import numpy as np
```

In [3]:

```
from neo4j import GraphDatabase
```

In [4]:

```
from pandas import DataFrame
```

In [5]:

```
import json
```

In [6]:

```
from yfiles_jupyter_graphs import GraphWidget
```

In [7]:

```
import matplotlib
```

In [8]:

```
from graphdatascience import GraphDataScience
```

In [43]:

```
pip install graphdatascience
```

...

2 Load data and create database

In [9]:

```
data = pd.read_csv('data_test.csv')
```

In [10]:

```
1 data[:4]
```

Out[10]:

	idEvent;FullName1;FullName2
0	189;Галчевская Карина Владимировна;Белоновская...
1	206;Офицеров Олег Романович;Сапожник Борис Вал...
2	445;Жандарова Лариса Германовна;Чемодуров Дами...
3	503;Масимова Яна Дамировна;Мингажетдинов Рамил...

In [11]:

```python
#Создадим класс для подключения к базе данных
class Neo4jConnection:
    def __init__(self, uri, user, password):
        self.driver = GraphDatabase.driver(uri, auth=(user, password))

    def close(self):
        if self.driver is not None:
            self.driver.close()

# Метод, который передает запрос в БД и возвращает данные в виде списка
    def query(self, query, db=None):
        assert self.driver is not None, "Driver not initialized!"
        session = None
        response = None
        try:
            session = self.driver.session(database=db) if db is not None else self.driv
            response = list(session.run(query))
        except Exception as e:
            print("Query failed:", e)
        finally:
            if session is not None:
                session.close()
        return response

# Метод, который передает запрос в БД и возвращает данные в виде графа
    def query_graph(self, query_graph, db=None):
        assert self.driver is not None, "Driver not initialized!"
        session = None
        response = None
        try:
            session = self.driver.session(database=db) if db is not None else self.driv
            response = session.run(query_graph).graph()
        except Exception as e:
            print("Query failed:", e)
        finally:
            if session is not None:
                session.close()
        return response

# Метод, который передает запрос в БД и возвращает данные в виде json
    def query_json(self, query_json, db=None):
        assert self.driver is not None, "Driver not initialized!"
        session = None
        response = None
        try:
            session = self.driver.session(database=db) if db is not None else self.driv
            response = session.run(query_json)
            data = response.data()
            data = json.dumps(data, ensure_ascii=False)
        except Exception as e:
            print("Query failed:", e)
        finally:
            if session is not None:
                session.close()
        return data


    # Метод, который передает запрос в БД с идентификатором и возвращает данные в виде
    def query_json_id(self, query_json_id, parametrs, db=None):
```

```
        assert self.driver is not None, "Driver not initialized!"
        session = None
        response = None
        try:
            session = self.driver.session(database=db) if db is not None else self.driv
            response = session.run(query_json_id, parametrs)
            data = response.data()
            data = json.dumps(data, ensure_ascii=False)
        except Exception as e:
            print("Query failed:", e)
        finally:
            if session is not None:
                session.close()
        return data

```

In [12]:

```
#Извлечем необходимые данные из ранее созданного файла(локалхост, узер, пароль) для пок
with open('entrance.txt','r') as ent:
    data = ent.read().split(',')
uri_my = eval(data[0].split('=')[1])
user_my = eval(data[1].split('=')[1])
password_my = eval(data[2].split('=')[1])
user_my
```

Out[12]:

```
'Ekaterina'
```

In [13]:

```
#Подключаемся к базе данных
conn = Neo4jConnection(uri=uri_my, user=user_my, password=password_my)
```

In [104]:

```
#Создаем пустую базу данных
conn.query("CREATE OR REPLACE DATABASE graphdb")
```

Out[104]:

```
[]
```

In [ ]:

```
#Создаем ноды и свойства участник события, используя информацию из файла data_test.csv
#query_string = '''
#LOAD CSV WITH HEADERS FROM
#'https://raw.githubusercontent.com/KaterinaChel/grath-DB/main/data_test.csv'
#AS line FIELDTERMINATOR ';'
#MERGE (member:Member {fullname: line.FullName1})
#  ON CREATE SET member.idEvent = line.idEvent
#  ON MATCH SET member.idEvent2 = line.idEvent
#MERGE (member2:Member {fullname: line.FullName2})
#  ON CREATE SET member2.idEvent = line.idEvent
#  ON MATCH SET member2.idEvent2 = line.idEvent;
#
#'''
#conn.query(query_string, db='graphdb')
```

In [105]:

```
#Создаем ноды и свойства участник события, используя информацию из файла data_test.csv
query_string = '''
LOAD CSV WITH HEADERS FROM
'https://raw.githubusercontent.com/KaterinaChel/grath-DB/main/data_test.csv'
AS line FIELDTERMINATOR ';'
MERGE (member:Member {fullname: line.FullName1})
  ON CREATE SET member.idEvent = line.idEvent
  on MATCH SET member.idEvent = apoc.convert.toSet(member.idEvent + [line.idEvent])
MERGE (member2:Member {fullname: line.FullName2})
  ON CREATE SET member2.idEvent = line.idEvent
  on MATCH SET member2.idEvent = apoc.convert.toSet(member2.idEvent + [line.idEvent]);

'''
conn.query(query_string, db='graphdb')
```

Out[105]:

```
[]
```

In [106]:

```
#Создаем ноды и свойства событие, используя информацию из файла data_test.csv
query_string = '''
LOAD CSV WITH HEADERS FROM
'https://raw.githubusercontent.com/KaterinaChel/grath-DB/main/data_test.csv'
AS line FIELDTERMINATOR ';'
MERGE (event:Event {idEvent: line.idEvent})
  ON CREATE SET event.fullname1 = line.FullName1
  ON CREATE SET event.fullname2 = line.FullName2
  ON MATCH SET event.fullname3 = line.FullName1
  ON MATCH SET event.fullname4 = line.FullName2;

'''
conn.query(query_string, db='graphdb')
```

Out[106]:

```
[]
```

In [30]:

```
#Создаем ноды и свойства событие, используя информацию из файла data_test.csv
#query_string = '''
#LOAD CSV WITH HEADERS FROM
#'https://raw.githubusercontent.com/KaterinaChel/grath-DB/main/data_test.csv'
#AS line FIELDTERMINATOR ';'
#MERGE (event:Event {idEvent: line.idEvent})
#  ON CREATE SET event.fullname1 = line.FullName1
#  ON CREATE SET event.fullname2 = line.FullName2
#  on MATCH SET event.fullname1 = apoc.convert.toSet(event.fullname1 + [line.FullName1]
#  on MATCH SET event.fullname2 = apoc.convert.toSet(event.fullname2 + [line.FullName2]

#'''
#conn.query(query_string, db='graphdb')
```

Out[30]:

```
[]
```

In [107]:

```
#Создаем отношения участник события -[участвовал]->событие
query_string ='''
LOAD CSV WITH HEADERS FROM 'https://raw.githubusercontent.com/KaterinaChel/grath-DB/mai
MATCH (member1:Member {fullname: line.FullName1})
MATCH (member2:Member {fullname: line.FullName2})
MATCH (event:Event {idEvent: line.idEvent})
CREATE (member1)-[:PARTICIPATE]->(event)
CREATE (member2)-[:PARTICIPATE]->(event);
'''
conn.query(query_string, db='graphdb')
```

Out[107]:

```
[]
```

3 Analysis graph db

In [19]:

```
#Выберем 100 случайных элементов участников событий для просмотра
query ='''
MATCH p = (m)-[*]-(e)
RETURN p LIMIT 100;
'''
data_t=conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_t)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

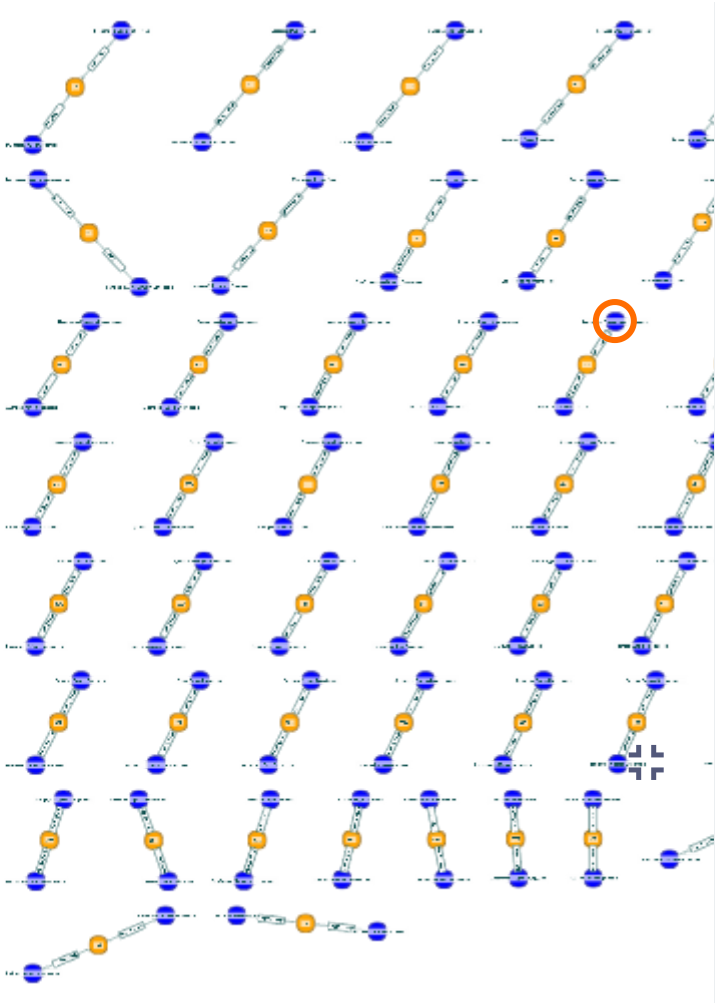

In [20]:

```
query_string ='''
MATCH(event:Event) RETURN Count(event);
'''
result_e=conn.query(query_string, db='graphdb')
count_e = int(''.join(filter(str.isdigit, str(result_e[0]))))
```

In [21]:

```
query_string ='''
MATCH(member:Member) RETURN Count(member);
'''
result_m = conn.query(query_string, db='graphdb')
count_m = int(''.join(filter(str.isdigit, str(result_m[0]))))
```

In [22]:

```
print(f"Number of members {count_m}, number of events {count_e} ")
```

```
Number of members 9899, number of events 4985
```

In [23]:

```
#Посмотрим отношение участников событий к самим событиям
df_result_count=pd.Series({"Member":count_m,"Event":count_e})
print(df_result_count)
df_result_count.plot(kind="bar",color=["green","yellow"])
plt.xlabel("Node Label")
plt.ylabel("No Of Nodes")
plt.show()
```

```
Member    9899
Event     4985
dtype: int64
```

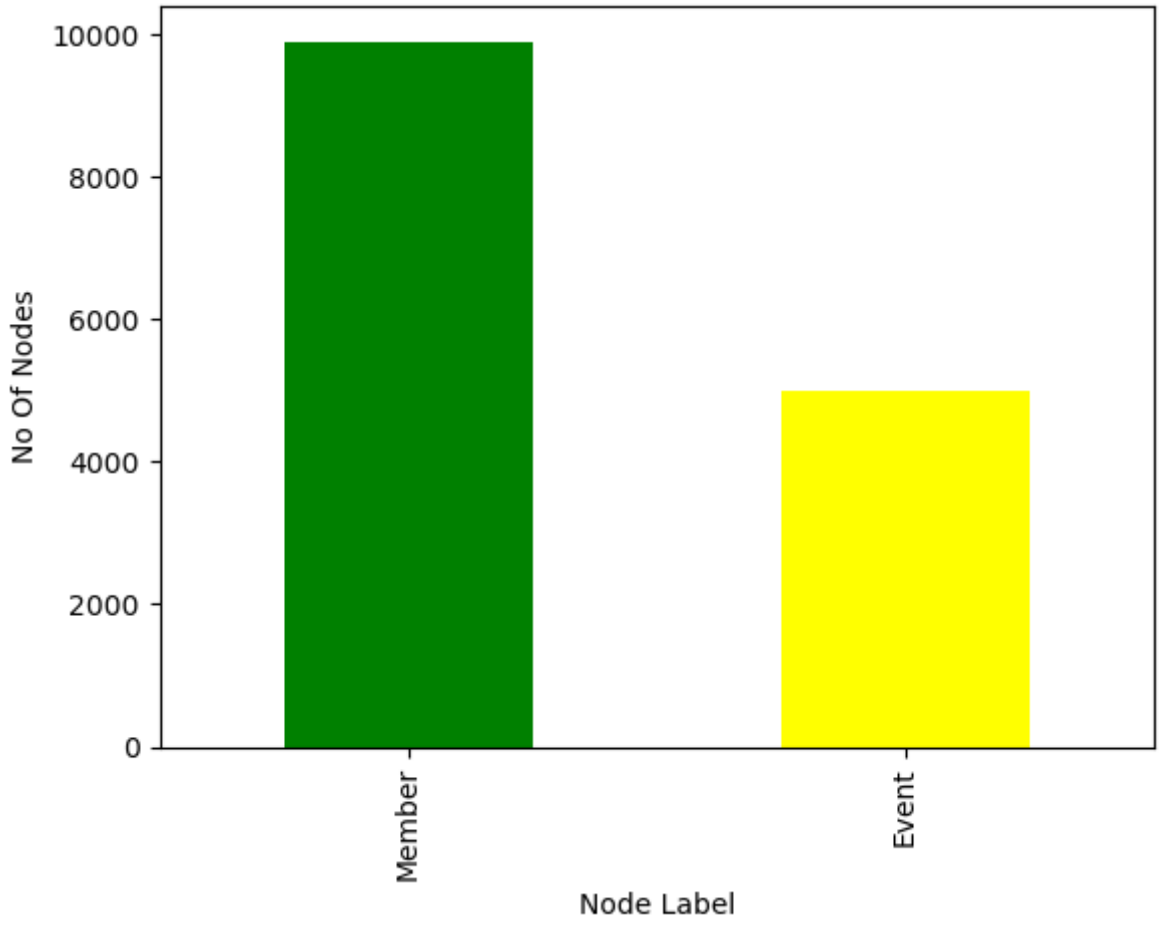

Событий меньше в ~ 2 раза, чем участников, однако не точно в 2 раза, а в 1,98 раза, можно предположить, что:

- есть участники, принимающие участие более, чем в 1ом событии,
- есть события, где принимает участие 1 участник, возможно есть пропуски в данных

In [24]:

```
#Посмотрим кто из нашей базы данных участвовал в более чем 1 событии.А также узнаем кол
query_string ='''
MATCH (m:Member)-[:PARTICIPATE]->(e:Event)
WITH m,collect(e.idEvent) as idEvent,count(*) as total
WHERE total >= 2
RETURN  m.fullname, idEvent,total
ORDER BY total DESC;
'''
data_total_event = conn.query(query_string, db='graphdb')
pd.DataFrame(data_total_event,columns=['FullName', 'idEvent', 'Total'])
```

Out[24]:

	FullName	idEvent	Total
0	Ахромеева Алина Ивановна	[42389, 53707, 59801, 61824, 89429, 90615, 128...	50
1	Башнина Антонина Глебовна	[66267, 208421, 224711, 292757, 370508, 379611...	14
2	Медведева Дарья Алексеевна	[87253, 109281, 173973, 196243, 327044, 580478]	6
3	Зимнухова Карина Даниловна	[132775, 241336, 346700, 348716, 504411]	5
4	Диомидов Игорь Ильдарович	[361353, 513700, 608245, 885195, 906600]	5
5	Шолохов Игорь Робертович	[218462, 750824, 829652, 875321]	4
6	Двигубская Валентина Геннадьевна	[218462, 355320, 798803]	3
7	Пафомова Кира Вадимовна	[99439, 829652, 958318]	3
8	Ляуданский Валентин Владиславович	[99439, 913605]	2
9	Мараховская Дарья Романовна	[732922, 958318]	2
10	Торгунаков Роман Кириллович	[750824, 913605]	2
11	Поскребышев Яков Дмитриевич	[799632, 815533]	2
12	Дорожкин Анатолий Егорович	[667986, 798803]	2
13	Яцкой Роберт Ильдарович	[684804, 745893]	2
14	Радионова Тамара Ярославовна	[590800, 608245]	2
15	Бугайчук Роман Эдуардович	[590800, 972769]	2
16	Троекуров Глеб Ефимович	[410960, 732922]	2
17	Нагайцева Анжелика Яновна	[410960, 875321]	2
18	Подолян Владислав Денисович	[195222, 799632]	2
19	Недовесков Владимир Иванович	[195222, 684804]	2
20	Каехтин Ильдар Эдуардович	[328508, 745893]	2
21	Майлина Гульнара Ивановна	[328508, 815533]	2
22	Анихнова Тамара Руслановна	[348716, 972769]	2
23	Ивашев Вячеслав Игоревич	[355320, 389500]	2
24	Рыскина Эльмира Ивановна	[389500, 912479]	2
25	Батиевская Ангелина Романовна	[294139, 667986]	2
26	Даниленко Владимир Семенович	[294139, 912479]	2

In [25]:

```
#Посмотрим есть ли в нашей базе данных такие участники, которые не приняли участия ни в
query_string ='''
MATCH (m:Member)-[:PARTICIPATE]->(e:Event)
WITH m,collect(e.idEvent) as idEvent,count(*) as total
WHERE total < 1
RETURN  m.fullname, idEvent,total
ORDER BY total DESC;
'''
data_total_event = conn.query(query_string, db='graphdb')
pd.DataFrame(data_total_event,columns=['FullName', 'idEvent', 'Total'])
```

Out[25]:

FullName	idEvent	Total

In [26]:

```
#Посмотрим какие события имеют более чем 2ух участника, а также ФИО таких участников
query_string ='''
MATCH (m:Member)-[:PARTICIPATE]->(e:Event)
WITH e,collect(e.fullname) as fullname,count(*) as total
WHERE total > 2
RETURN e.idEvent, e.fullname1,e.fullname2, e.fullname3, e.fullname4, total
ORDER BY total DESC;
'''
data_total_full_name = conn.query(query_string, db='graphdb')
pd.DataFrame(data_total_full_name,columns=['idEvent', 'FullName1', 'FullName2','FullNam
```

Out[26]:

	idEvent	FullName1	FullName2	FullName3	FullName4	Total
0	70049	Яшина Полина Евгеньевна	Герасимовская Ксения Дамировна	Федова Анжелика Вадимовна	Вальдовский Альберт Ефимович	4
1	92995	Журик Альберт Евгеньевич	Бадьянова Римма Максимовна	Кучеренко Ирина Ильинична	Болтик Григорий Максимович	4
2	938764	Солтаганов Федор Ефимович	Хрисогонов Иван Геннадьевич	Самолов Михаил Алексеевич	Двигубская Яна Ивановна	4
3	985851	Павлюкова Наталья Федоровна	Клебан Игорь Глебович	Липунова Галина Ринатовна	Ноткина Альбина Михаиловна	4
4	850472	Стрик Элина Марселевна	Борчин Павел Робертович	Ахромеева Алина Ивановна	Ларищев Илья Александрович	4
5	873359	Якимихина Наталья Яновна	Улиссов Марсель Эдуардович	Джанибеков Никита Юрьевич	Старовойтов Вячеслав Павлович	4
6	765223	Савлук Марсель Владимирович	Атамкулова Мария Андреевна	Бабосов Михаил Константинович	Гулева Марина Витальевна	4
7	716489	Пантелюхина Лариса Вячеславовна	Штин Максим Русланович	Адельханова Елена Петровна	Арсенчук Руслан Денисович	4
8	523688	Бацких Егор Олегович	Барилов Роман Филиппович	Ботяновская Антонина Даниловна	Памфилова Тамара Даниловна	4
9	551592	Захарьева Ирина Денисовна	Солонченко Карина Васильевна	Выборнов Дмитрий Дмитриевич	Нугуманов Ефим Андреевич	4
10	613539	Гавриленко Глеб Марселевич	Ганенко Эльмира Степановна	Сахнова Тамара Васильевна	Кишенин Станислав Георгиевич	4
11	358194	Ноева Галина Степановна	Серпухова Алла Ярославовна	Долгих Лилия Вадимовна	Брусенцова Дарья Михаиловна	4
12	390312	Григорьевых Павел Леонидович	Хилин Федор Федорович	Намазова Евгения Дмитриевна	Охоцимская Виктория Евгеньевна	4
13	117280	Волынский Кирилл Федорович	Гайсумов Виктор Тимурович	Уточкин Евгений Анатольевич	Каганович Лилия Петровна	4
14	177407	Зелинский Геннадий Артурович	Зазорин Вадим Аркадьевич	Бужанинов Руслан Артурович	Сороковой Герман Маратович	4

In [27]:

```
#Посмотрим есть ли такие события, где принимало участие менее 2ух человек
query_string ='''
MATCH (m:Member)-[:PARTICIPATE]->(e:Event)
WITH e,collect(e.fullname) as fullname,count(*) as total
WHERE total < 2
RETURN e.idEvent, e.fullname1,e.fullname2,e.fullname3,e.fullname4,total
ORDER BY total DESC;
'''
data_total_full_name = conn.query(query_string, db='graphdb')
pd.DataFrame(data_total_full_name,columns=['idEvent', 'FullName1', 'FullName2','FullNam
```

Out[27]:

idEvent	FullName1	FullName2	FullName3	FullName4	Total

3.1 Промежуточные выводы:

- С большой долей вероятности данные полные, отсутствуют ошибки,
- Стандартное событие содержит 2 участников, которые принимали участие только в 1 событии из базы данных
- 27 участников приняли участие более, чем в 1 событии,
- 15 событий имеют по 4 участника.

На основе этой информации, мы можем предположить, что часть участников связаны с другими участниками не напрямую, а через других участников. Посмотрим, выведем граф со всеми участниками и их связями для участников кол-во событий >=2

In [28]:

```
#Данный запрос выводит все связанные ноды и связи для участников с количеством событий
query ='''
MATCH p = (member1:Member)-->(event:Event)<--(member2:Member)
WHERE member1.idEvent <> member2.idEvent
RETURN p;
'''
data_t=conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_t)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

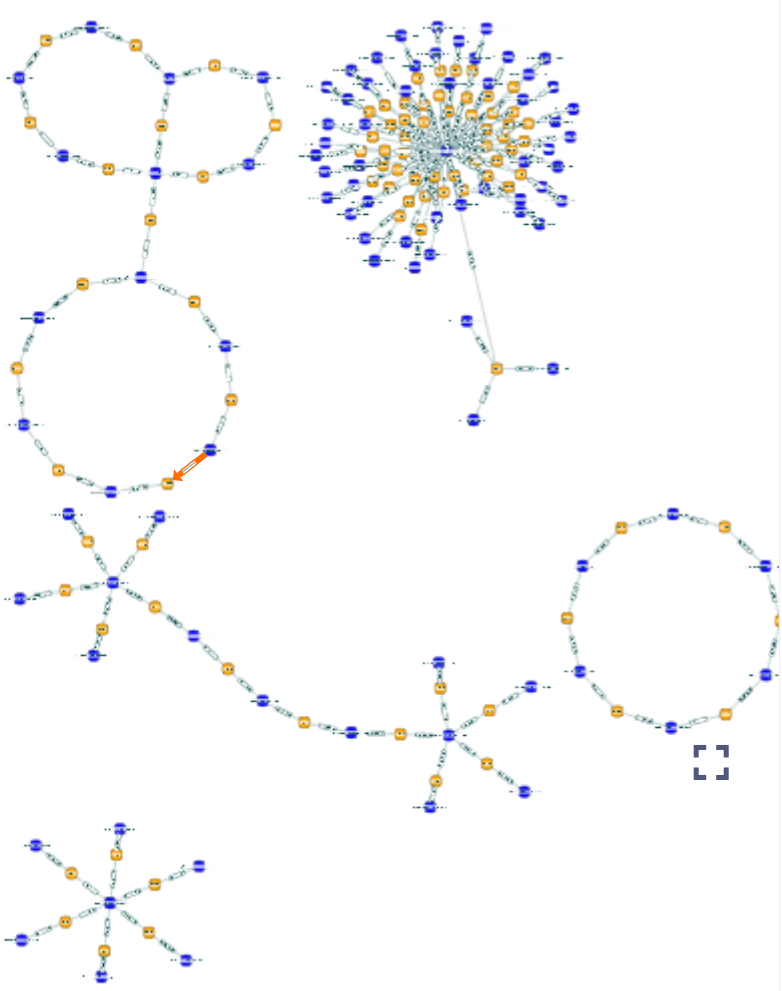

In [29]:

```
#Данный запрос выводит все события с количеством участников более 2
query ='''
MATCH p = (member1:Member)-->(event:Event)<--(member2:Member)
WHERE event.fullname3 IS NOT NULL
RETURN p;
'''
data_t=conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_t)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

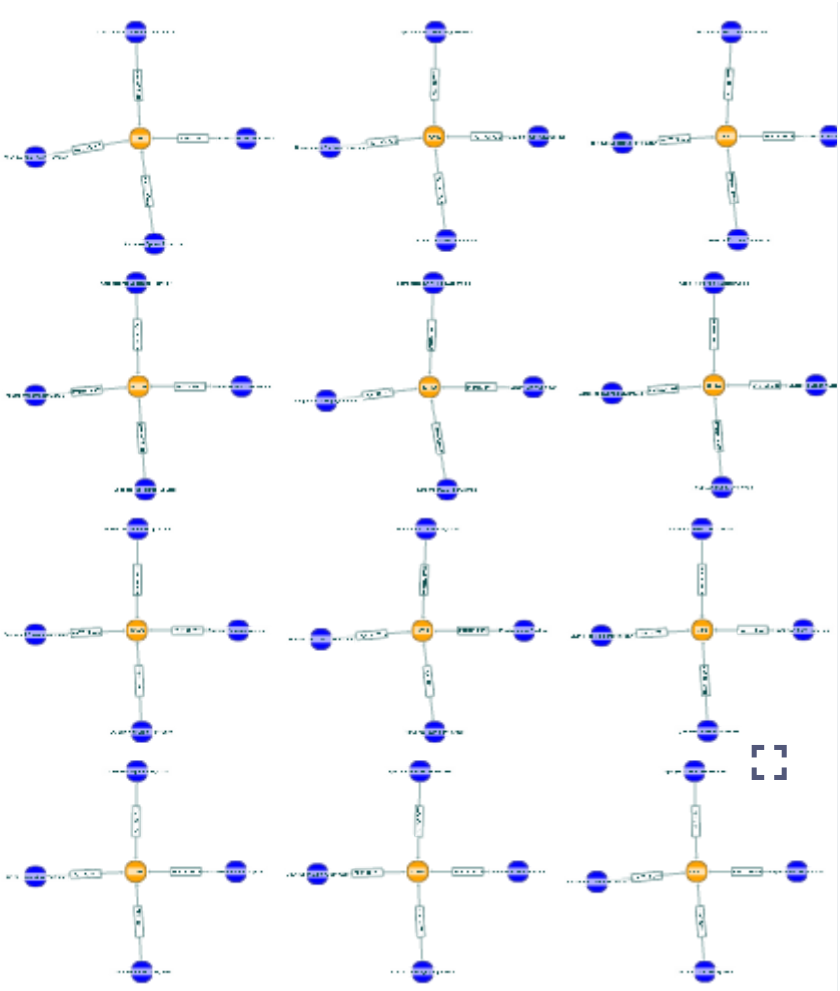

По данным графовым представлениям можно сделать вывод, что 15 событий являются наиболее значимыми, так как в них принимают участие не 2 участника, а 4. Так как все остальные 4970 событий содержат только 2 участников, такие события являются аномальными и на них стоит обратить особое внимание.

In [30]:

```
#Запросим информацию о конкретном человеке и событиях, где он участвовал
query ='''
MATCH p = (m:Member)-[:PARTICIPATE]-(e)
WHERE m.fullname = 'Ахромеева Алина Ивановна'
RETURN p;
'''
data_ahromeeva = conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_ahromeeva)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

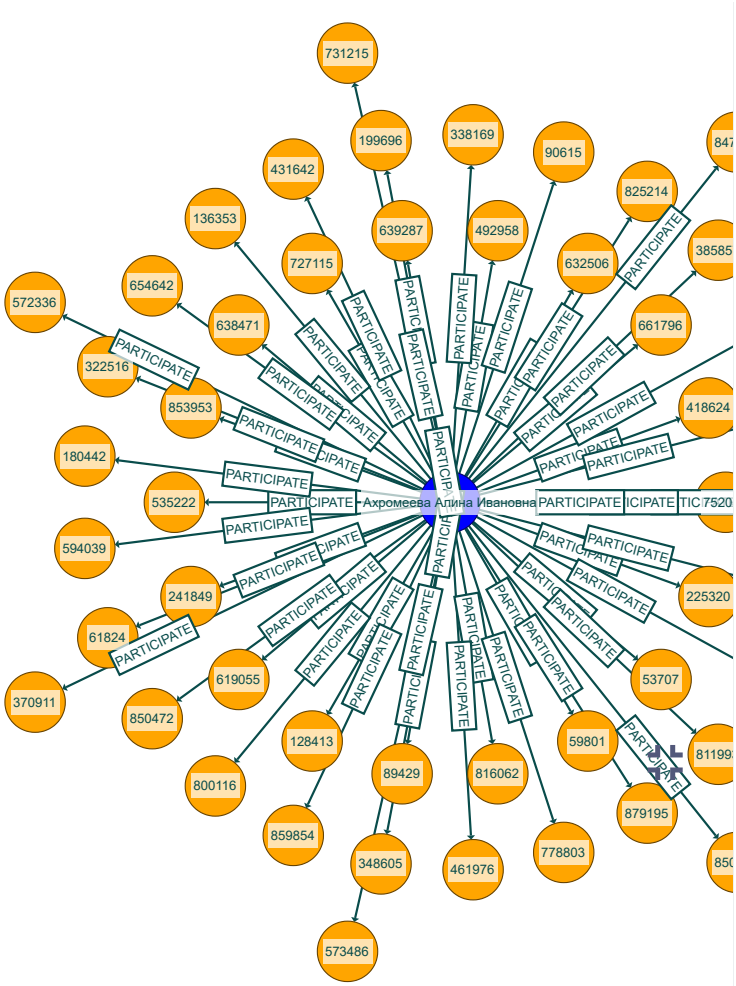

In [31]:

```
#Запросим информацию о конкретном человеке, событиях, где он участвовал, а также участн
query ='''
MATCH p = (m:Member)-[*]-(e)
WHERE m.fullname = 'Ахромеева Алина Ивановна'
RETURN p;
'''
data_ahromeeva = conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_ahromeeva)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

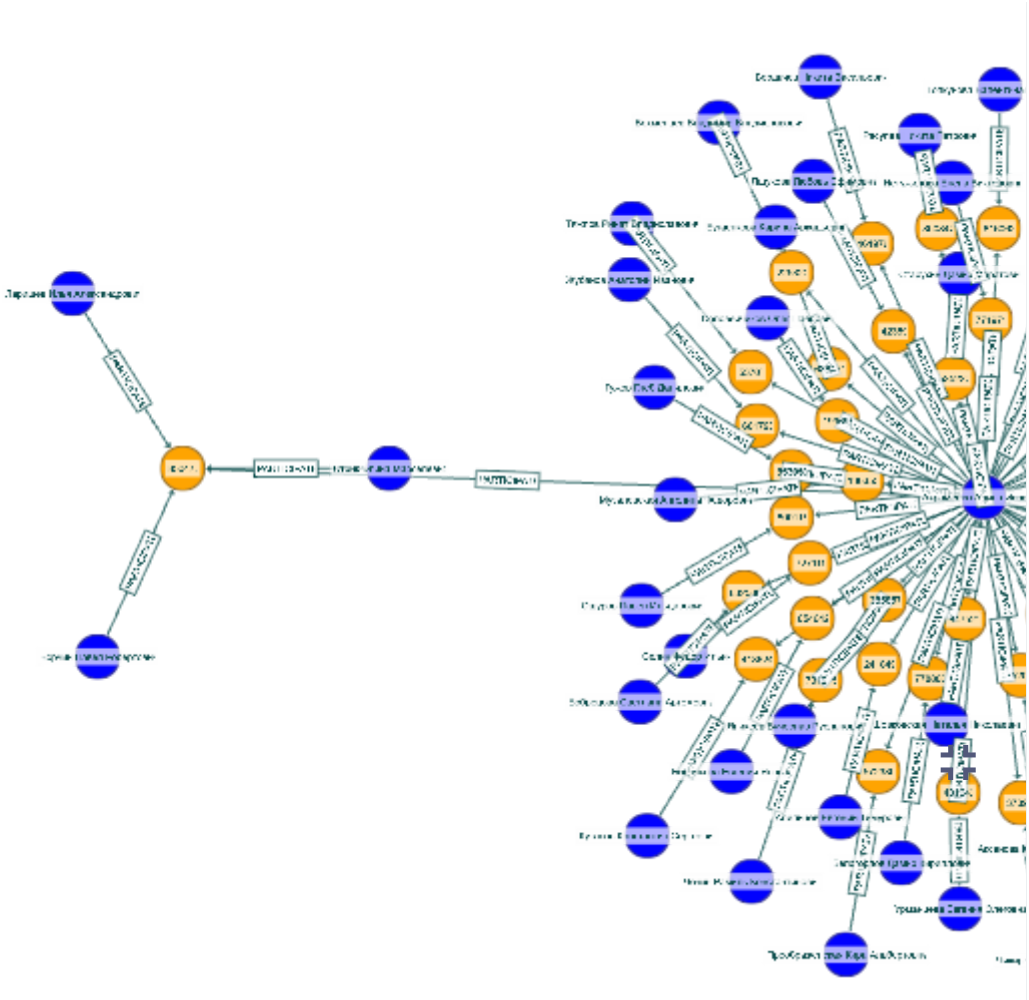

По данному графу, можно сделать вывод, что участник Ахромеева Алина Ивановна является центральным участником, через нее можно перейти к любому другому частнику графа. Можно предположить, что участник Ахромеева Алина Ивановна играет роль не просто участник событий, а в зависимости от типа событий организатор, мошенник, разносчик вируса и т.д.

In [33]:

```
#Запросим информацию о конкретном человеке, событиях, где он участвовал, а также участн
query ='''
MATCH p = (m:Member)-[*]-(e)
WHERE m.fullname = 'Башнина Антонина Глебовна'
RETURN p;
'''
data_ahromeeva = conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_ahromeeva)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

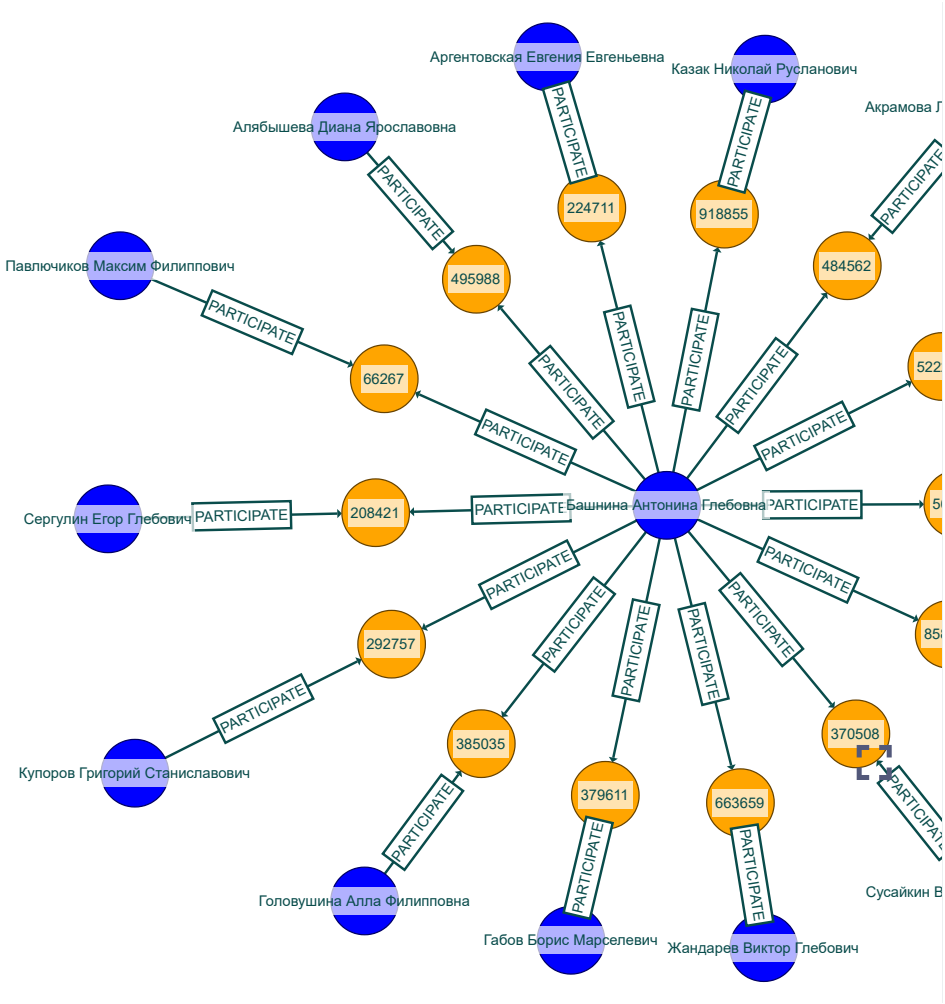

По данному графу, можно сделать вывод, что участник Башнина Антонина Глебовна является центральным участником, через нее можно перейти к любому другому частнику графа. Можно предположить, что участник Башнина Антонина Глебовна играет роль не просто участник событий, а в зависимости от типа событий организатор, мошеник, разнощик вируса и т.д.

In [34]:

```
#Запросим информацию о конкретном человеке, событиях, где он участвовал, а также участн
query ='''
MATCH p = (m:Member)-[*]-(e)
WHERE m.fullname = 'Медведева Дарья Алексеевна'
RETURN p;
'''
data_ahromeeva = conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_ahromeeva)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

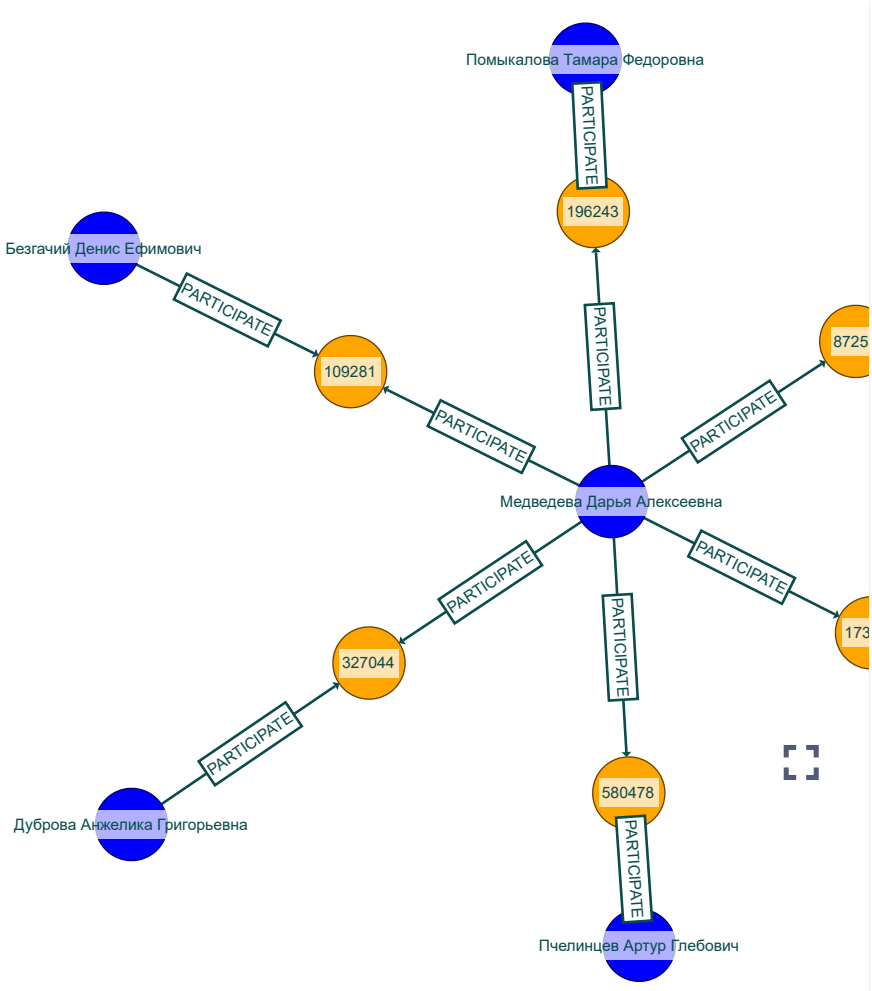

По данному графу, можно сделать вывод, что участник Медведева Дарья Алексеевна является центральным участником, через нее можно перейти к любому другому частнику графа. Можно предположить, что участник Медведева Дарья Алексеевна играет роль не просто участник событий, а в зависимости от типа событий организатор, мошеник, разнощик вируса и т.д.

In [35]:

```
#Запросим информацию о конкретном человеке, событиях, где он участвовал, а также участн
query ='''
MATCH p = (m:Member)-[*]-(e)
WHERE m.fullname = 'Двигубская Валентина Геннадьевна'
RETURN p;
'''
data_ahromeeva = conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_ahromeeva)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

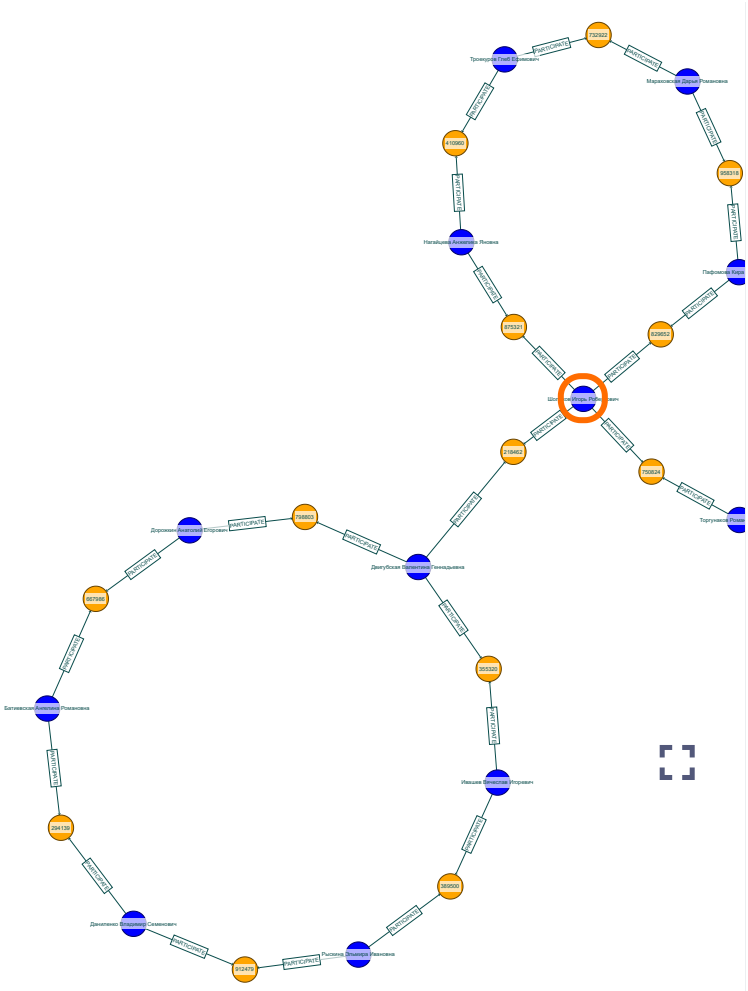

По данному графу можно сделать вывод, что есть 3 наиболее значимых участника - Двигубская Валентина Геннадьевна, Шолохов Игорь Робертович и Пафомова Кира Вадимовна. Данные лица, участвовали более чем в 2ух событиях и с помощью них осуществилась связь частей графа. Также, можно предположить наличие 3ех сообществ.

In [36]:

```
#Запросим информацию о конкретном человеке, событиях, где он участвовал, а также участн
query ='''
MATCH p = (m:Member)-[*]-(e)
WHERE m.fullname = 'Зимнухова Карина Даниловна'
RETURN p;
'''
data_ahromeeva = conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_ahromeeva)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

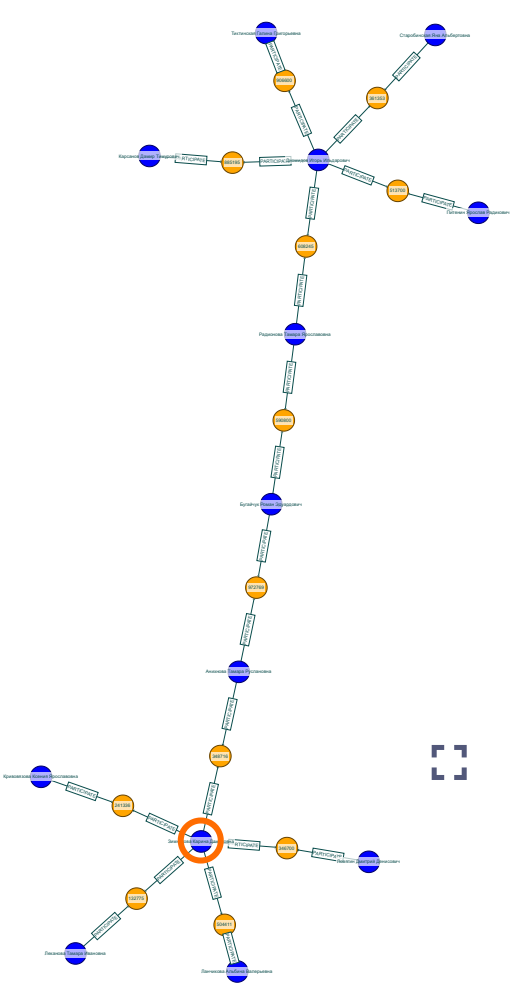

По данному графу можно сделать вывод, что есть 2 наиболее значимых участника - Диомидов Игорь Ильдарович, Зимнухова Карина Даниловна. Данные лица, участвовали более в 5 событиях и с помощью них осуществилась связь частей графа.

In [38]:

```
#Запросим информацию о конкретном человеке, событиях, где он участвовал, а также участн
query ='''
MATCH p = (m:Member)-[*]-(e)
WHERE m.fullname = 'Яцкой Роберт Ильдарович'
RETURN p;
'''
data_ahromeeva = conn.query_graph(query, db='graphdb')
w = GraphWidget(graph=data_ahromeeva)
w.set_node_color_mapping(lambda index, node: "blue" if node["properties"]["label"] == '
w.set_node_label_mapping(lambda index, node: node["properties"]["fullname"] if node["pr
w.show()
```

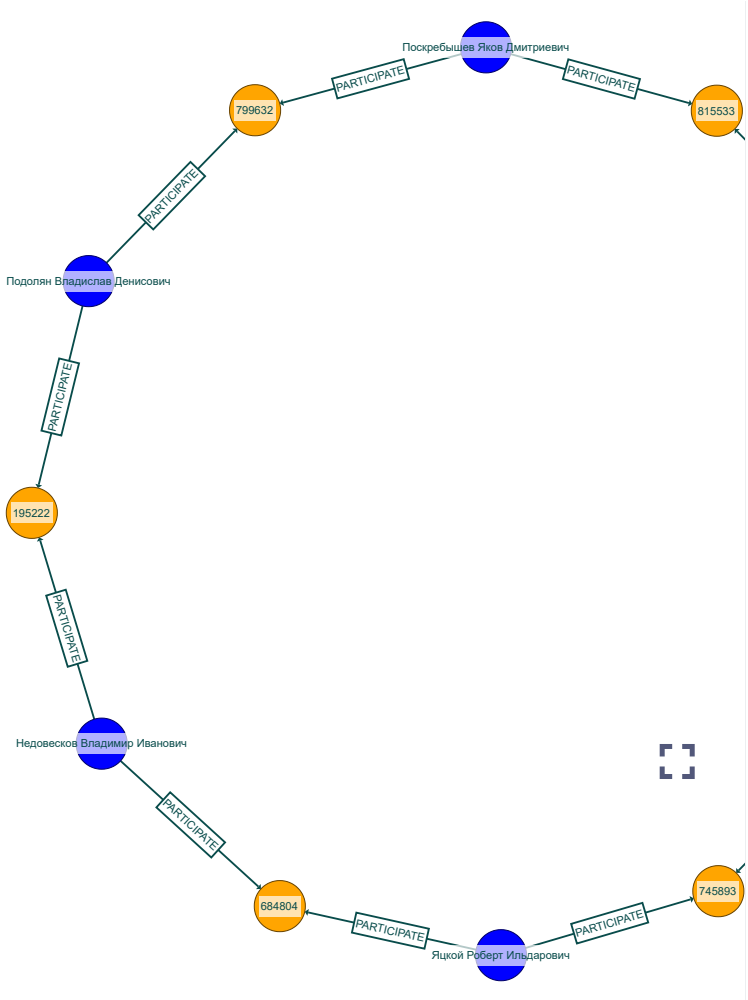

По данному графу можно предположить, что участники являются частью сообщества, или если это транзакции, то такие схемы могут использоваться для отмывания денег, но скорее присуще компаниям, нежели физическим лицам.

In [33]:

```
query_string ='''
MATCH (m:Member)-[:PARTICIPATE]->(:Event)<-[:PARTICIPATE]-(m2)
WHERE id(m) < id(m2)
WITH m,m2, count(*) AS common
RETURN count(*) AS numberOfRows;
'''
conn.query(query_string, db='graphdb')
```

Out[33]:

```
[<Record numberOfRows=5060>]
```

In [63]:

```
#Выведем в формате json информацию о конкретном участники событий:событие, участник1, у
query ='''
MATCH (member1:Member{fullname:'Башнина Антонина Глебовна'})-->(event:Event)<--(member2
RETURN member1.fullname AS Member1, member2.fullname AS Member2, event.idEvent AS idEve
'''
data_s=conn.query_json(query, db='graphdb')
data_s
```

Out[63]:


```
'[{"Member1": "Башнина Антонина Глебовна", "Member2": "Купоров Григорий Стан
ославович", "idEvent": "292757"}, {"Member1": "Башнина Антонина Глебовна",
"Member2": "Казак Николай Русланович", "idEvent": "918855"}, {"Member1": "Ба
шнина Антонина Глебовна", "Member2": "Павлючиков Максим Филиппович", "idEven
t": "66267"}, {"Member1": "Башнина Антонина Глебовна", "Member2": "Аргентовс
кая Евгения Евгеньевна", "idEvent": "224711"}, {"Member1": "Башнина Антонина
Глебовна", "Member2": "Фефилов Дмитрий Янович", "idEvent": "563736"}, {"Memb
er1": "Башнина Антонина Глебовна", "Member2": "Алябышева Диана Ярославовна",
"idEvent": "495988"}, {"Member1": "Башнина Антонина Глебовна", "Member2": "А
крамова Людмила Альбертовна", "idEvent": "484562"}, {"Member1": "Башнина Ант
онина Глебовна", "Member2": "Головушина Алла Филипповна", "idEvent": "38503
5"}, {"Member1": "Башнина Антонина Глебовна", "Member2": "Габов Борис Марсел
евич", "idEvent": "379611"}, {"Member1": "Башнина Антонина Глебовна", "Membe
r2": "Сергулин Егор Глебович", "idEvent": "208421"}, {"Member1": "Башнина Ан
тонина Глебовна", "Member2": "Сусайкин Владимир Ярославович", "idEvent": "37
0508"}, {"Member1": "Башнина Антонина Глебовна", "Member2": "Недоквасов Влад
ислав Константинович", "idEvent": "858935"}, {"Member1": "Башнина Антонина Г
лебовна", "Member2": "Жандарев Виктор Глебович", "idEvent": "663659"}, {"Mem
ber1": "Башнина Антонина Глебовна", "Member2": "Челомбитько Тимофей Антонови
ч", "idEvent": "522249"}]'
```

In [14]:

```
query ='''
MATCH (member1:Member)-->(event:Event)<--(member2:Member)
WHERE ID(member1) = 341
RETURN member1.fullname AS Member1, member2.fullname AS Member2, event.idEvent AS idEve
'''
data_s=conn.query_json(query, db='graphdb')
data_s
```

Out[14]:


```
'[{"Member1": "Башнина Антонина Глебовна", "Member2": "Купоров Григорий Стан
иславович", "idEvent": "292757"}, {"Member1": "Башнина Антонина Глебовна",
"Member2": "Казак Николай Русланович", "idEvent": "918855"}, {"Member1": "Ба
шнина Антонина Глебовна", "Member2": "Павлючиков Максим Филиппович", "idEven
t": "66267"}, {"Member1": "Башнина Антонина Глебовна", "Member2": "Аргентовс
кая Евгения Евгеньевна", "idEvent": "224711"}, {"Member1": "Башнина Антонина
Глебовна", "Member2": "Фефилов Дмитрий Янович", "idEvent": "563736"}, {"Memb
er1": "Башнина Антонина Глебовна", "Member2": "Алябышева Диана Ярославовна",
"idEvent": "495988"}, {"Member1": "Башнина Антонина Глебовна", "Member2": "А
крамова Людмила Альбертовна", "idEvent": "484562"}, {"Member1": "Башнина Ант
онина Глебовна", "Member2": "Головушина Алла Филипповна", "idEvent": "38503
5"}, {"Member1": "Башнина Антонина Глебовна", "Member2": "Габов Борис Марсел
евич", "idEvent": "379611"}, {"Member1": "Башнина Антонина Глебовна", "Membe
r2": "Сергулин Егор Глебович", "idEvent": "208421"}, {"Member1": "Башнина Ан
тонина Глебовна", "Member2": "Сусайкин Владимир Ярославович", "idEvent": "37
0508"}, {"Member1": "Башнина Антонина Глебовна", "Member2": "Недоквасов Влад
ислав Константинович", "idEvent": "858935"}, {"Member1": "Башнина Антонина Г
лебовна", "Member2": "Жандарев Виктор Глебович", "idEvent": "663659"}, {"Mem
ber1": "Башнина Антонина Глебовна", "Member2": "Челомбитько Тимофей Антонови
ч", "idEvent": "522249"}]'
```


In [48]:

```
#Выведем в формате json информацию о конкретном участники событий:участник, события, ко
query ='''
MATCH (member:Member{fullname:'Башнина Антонина Глебовна'})-[:PARTICIPATE]->(event:Ever
WITH member,collect(event.idEvent) as idEvent,count(*) as total
RETURN member.fullname AS Member, idEvent, total;
'''
data_s=conn.query_json(query, db='graphdb')
data_s
```

Out[48]:


```
'[{"Member": "Башнина Антонина Глебовна", "idEvent": ["292757", "918855", "6
6267", "224711", "563736", "495988", "484562", "385035", "379611", "208421",
"370508", "858935", "663659", "522249"], "total": 14}]'
```

In [64]:

```
query ='''
MATCH (member:Member{fullname:$name})-[:PARTICIPATE]->(event:Event)
WITH member,collect(event.idEvent) as idEvent,count(*) as total
RETURN member.fullname AS Member, idEvent, total;
'''
parametrs = {"name":"Башнина Антонина Глебовна"}
data_s=conn.query_json_id(query, parametrs, db='graphdb')
data_s
```

Out[64]:

```
'[{"Member": "Башнина Антонина Глебовна", "idEvent": ["292757", "918855", "6
6267", "224711", "563736", "495988", "484562", "385035", "379611", "208421",
"370508", "858935", "663659", "522249"], "total": 14}]'
```

4 Analysis with GDS

In [40]:

```
#Создаем пустую базу данных
conn.query("CREATE OR REPLACE DATABASE graphdb")
```

Out[40]:

```
[]
```

In [41]:

```
#Создаем ноды и свойства участник события, используя информацию из файла data_test.csv
query_string = '''
LOAD CSV WITH HEADERS FROM
'https://raw.githubusercontent.com/KaterinaChel/grath-DB/main/data_test.csv'
AS line FIELDTERMINATOR ';'
MERGE (member:Member {fullname: line.FullName1})
  ON CREATE SET member.idEvent = line.idEvent
  on MATCH SET member.idEvent = apoc.convert.toSet(member.idEvent + [line.idEvent])
MERGE (member2:Member {fullname: line.FullName2})
  ON CREATE SET member2.idEvent = line.idEvent
  on MATCH SET member2.idEvent = apoc.convert.toSet(member2.idEvent + [line.idEvent]);

'''
conn.query(query_string, db='graphdb')
```

Out[41]:

```
[]
```

In [42]:

```
#Создаем отношения участник события -[участвовал]->участик события
query_string ='''
LOAD CSV WITH HEADERS FROM 'https://raw.githubusercontent.com/KaterinaChel/grath-DB/mai
MATCH (member1:Member {fullname: line.FullName1})
MATCH (member2:Member {fullname: line.FullName2})
CREATE (member1)-[:PARTICIPATE]->(member2)
CREATE (member2)-[:PARTICIPATE]->(member1);
'''
conn.query(query_string, db='graphdb')
```

Out[42]:

```
[]
```

In [43]:

```
gds = GraphDataScience(uri_my, auth=(user_my, password_my), database="graphdb")
```

In [44]:

```
gds.run_cypher("MATCH (n) return labels(n) as labels, count(*) as nodeCount")
```

Out[44]:

	labels	nodeCount
0	[Member]	9899

Создадим проекцию графа. Проекции графов полностью хранятся в памяти с использованием сжатых структур данных, оптимизированных для топологии и поиска свойств.

In [72]:

```
Member_relait, result = gds.graph.project("relait", "Member", "PARTICIPATE")
result
```

Out[72]:

```
nodeProjection            {'Member': {'label': 'Member', 'properties': {}}}
relationshipProjection    {'PARTICIPATE': {'orientation': 'NATURAL', 'in...
graphName                                                            relait
nodeCount                                                              9899
relationshipCount                                                     10000
projectMillis                                                            19
Name: 0, dtype: object
```

In [73]:

```
wcc_memb = gds.wcc.stats(Member_relait)
wcc_memb
```

Out[73]:

```
componentCount                                                    4903
componentDistribution    {'p99': 2, 'min': 2, 'max': 51, 'mean': 2.0189...
postProcessingMillis                                                 4
preProcessingMillis                                                  0
computeMillis                                                        8
configuration            {'jobId': '09719b09-6d0d-4907-8609-6e0238fbfac...
Name: 0, dtype: object
```

In [74]:

```
wcc_memb['componentDistribution']
```

Out[74]:

```
{'p99': 2,
 'min': 2,
 'max': 51,
 'mean': 2.018967978788497,
 'p90': 2,
 'p50': 2,
 'p999': 7,
 'p95': 2,
 'p75': 2}
```

Статистически подтвердили, что среднее кол-во участников событий близко к 2. Посмотрели максиммальное, минимальное и рандомные значения

In [75]:

```
gds.graph.list()
```

Out[75]:

	degreeDistribution	graphName	database	memoryUsage	sizeInBytes	nodeCount	relationshi
0	{'p99': 1, 'min': 1, 'max': 50, 'mean': 1.0102...	myGraph	graphdb	2862 KiB	2931320	9899	
1	{'p99': 1, 'min': 1, 'max': 50, 'mean': 1.0102...	relait	graphdb	2862 KiB	2931320	9899	

In [76]:

```
pagerank_df_member = gds.pageRank.stream(Member_relait)
```

In [83]:

```
pagerank_df_member.max()
```

Out[83]:

```
nodeId    9898.000000
score       22.602141
dtype: float64
```

In [103]:

```
pagerank_df_member.sort_values(by = 'score', ascending=False)
```

Out[103]:

	nodeId	score
221	221	22.602141
341	341	6.702704
873	873	3.169496
661	661	2.496732
1794	1794	2.496732
...	...	...
9202	9202	0.528422
8066	8066	0.528422
7993	7993	0.528422
8790	8790	0.528422
9160	9160	0.528422

9899 rows × 2 columns

С помощью алгоритма pagerank мы можем определить центральные ноды, как и ожидалось, нода 221 - это Ахромеева Алина Ивановна.Все ноды с высоким показателем это выделенные ноды при визуальном осмотре графа -

- Ахромеева Алина Ивановна,22.602140755580333
- Башнина Антонина Глебовна,6.702703810275546
- Медведева Дарья Алексеевна,3.169495600207817
- Диомидов Игорь Ильдарович,2.496731732954958
- Зимнухова Карина Даниловна,2.496731732954958
- Шолохов Игорь Робертович,1.5114704293475534
- Двигубская Валентина Геннадьевна,1.2016188887270551
- Пафомова Кира Вадимовна,1.1706822673166937

In [71]:

```
gds.graph.drop(Member_relait)
```

Out[71]:

```
graphName                                                       relait
database                                                        graphdb
memoryUsage
sizeInBytes                                                         -1
nodeCount                                                         9899
relationshipCount                                                10000
configuration           {'relationshipProjection': {'PARTICIPATE': {'o...
density                                                       0.000102
creationTime                          2023-04-05T10:47:27.086869600+03:00
modificationTime                      2023-04-05T10:52:25.265706400+03:00
schema                  {'graphProperties': {}, 'relationships': {'PAR...
schemaWithOrientation   {'graphProperties': {}, 'relationships': {'PAR...
Name: 0, dtype: object
```

Выводы:

- база данных содержит 6 сложных сообществ
- выявлено 15 аномальных событий с количеством участников 4
- определено 8 самых значимых участников
- в каждом сложном событии определены центральные участники, при их наличии
- создана проекция графа. В зависимости от целей и типа данных можно далее продолжать работу с библиотекой GDS, в том числе для построения ML моделей
- в зависимости от типа данных, результаты можно использовать для рекомендации событий/ участников, обнаружения мошенических транзакций, обнаружения источника вируса и т.д.

In [ ]:

```

```